Projekt

Analiza podataka o igračima NHL lige

Uvod

U ovom projektu analizirat ćemo podatke o igračima NHL lige. Dobiveni podaci su opširni i sadrže mnogo međusobno povezanih informacija te ćemo se zato fokusirati na manji odabrani podskup. Bavit ćemo se osvojenim bodovima igrača, preferiranom rukom za udarce, pozicijama i plaćama igrača koje ćemo naposlijetku izmodelirati regresijom. Dodati još neke stvari o hokeju jer ja ne znam nista o hokeju

Analiza u ovom radu sastoji se od tri dijela: deskriptivna analiza, testovi sredina i intervalne procjene, te analiza zasnovana na linearnoj regresiji i analizi varijance.

Deskriptivna analiza

Učitavamo podatke i analiziramo kako oni izgledaju.

```
s = players.data$Salary
s = as.data.frame.numeric(s)
s <- as.numeric(unlist(s))</pre>
```

Histogramima ćemo prikazati razdiobu plaća igrača na logaritamskoj skali i umanjene 1000 puta. Promatranjem prikaza i testom normalnosti zaključujemo da se ne radi o normalnoj distribuciji, nego desno zakrivljenoj.

Testiranje hipoteza

Pretpostavka: igrači na nekoj određenoj poziciji značajno su više plaćeni od od drugih igrača

Igrače s miješanim pozicijama generalizirat ćemo po prvoj spomenutoj poziciji tako da svaki igrač ima samo jednu poziciju.

```
for (column_name in c("LW/RW", "LW/C", "LW/C/RW", "LW/RW/C", "LW")){
    players_copy$Position[players_copy$Position == column_name] = "L";
}
for (column_name in c("RW/C", "C/RW", "RW/LW","LW/C/RW", "RW/C/LW", "RW/LW/C", "C/LW/RW", "C/RW/LW", "R
    players_copy$Position[players_copy$Position == column_name] = "R";
}
for (column_name in c("LW/C", "C/LW","C/LW/RW", "C/RW/LW", "C", "C/RW", "C/LW/C")){
    players_copy$Position[players_copy$Position == column_name] = "C";
}
for (column_name in c("D/C", "C/D", "D/RW", "D/LW")){
    players_copy$Position[players_copy$Position == column_name] = "D";
}
#for (column_name in c("LW/C/RW", "C/RW/LW", "LW/RW/C", "RW/C/LW", "RW/LW/C", "C/LW/RW", "C/RW/LW")){
    # players_copy$Position[players_copy$Position == column_name] = "C/LW/RW";
```

Iz slijedećih boxplotova nije vidljiva bitna razlika u plaćama igrača na različitim pozicijama. Zamjećujemo da pozicija "D" ima nešto veći medijan od ostalih pozicija. To možemo pokušati provjeriti ANOVA metodom.

Pretpostavke ANOVA metode su nezavisnost podataka, normalna distribucija i homogenost varijanci, pa ćemo homogenost varijanci provjeriti Bartletovim testom:

$$H_0: \sigma_{"L"}^2 = \sigma_{"R"}^2 = \sigma_{"C"}^2 = \sigma_{"D"}^2$$

 $H_1: \neg H_0.$

razine značajnosti $\alpha = 0.05$.

```
1 <- subset(players.data.d, Position == "L")
bartlett.test(Salary~Position, players_copy)
##
## Bartlett test of homogeneity of variances</pre>
```

##
data: Salary by Position
Bartlett's K-squared = 8.5412, df = 3, p-value = 0.03606

Dobivena p vrijednost manja je od razine značajnosti što znači da se odbacuje H_0 pa ne možemo koristiti ANOVA-u. Umjesto ANOVA-e provest ćemo neparametarski test, Kruskal-Wallis test razine značajnosti $\alpha=0.05$ koji za sobom ne povlači pretpostavke koje dolaze s parametarskim testovima. Kruskal-Wallis test slabiji je od ANOVA-e i uspoređuje medijane, ali ovaj test u kombinaciji s gornjim prikazom dokazat će približnu jednakost plaća po pozicijama igrača.

$$H_0: M_{"L"} = M_{"R"} = M_{"C"} = M_{"D"}$$

 $H_1: \neg H_0.$

```
kruskal.test(Salary~Position, players_copy)
```

```
##
## Kruskal-Wallis rank sum test
##
## data: Salary by Position
## Kruskal-Wallis chi-squared = 3.2485, df = 3, p-value = 0.3549
```

Dobivena p-vrijednost veća je od razine značajnosti te iz toga zaključujemo da su plaće igrača ne razlikuju značajno po njihovim pozicijama. Ne odbacujemo H_0 .

Pretpostavka: igrači na nekoj određenoj poziciji postižu značajno više bodova od drugih igrača


```
require(fastDummies)
players.data.d <- dummy_cols(players_copy,select_columns='Position')
#View(players.data.d)

#data of potential outliers
players.data.d$PTS <- as.numeric(players.data.d$PTS)
out<-boxplot.stats(players.data.d$PTS)$out
out_ind <- which(players.data.d$PTS %in% c(out))
out_ind</pre>
```

[1] 22 150 390 427 486 510 705


```
#boxplot
ggplot(players.data.d) +
  aes(x = "", y = as.numeric(PTS)) +
  geom_boxplot(fill = "#0c4c8a") +
  theme_minimal()
   100
    75
as.numeric(PTS)
    25
     0
                                                 Х
#qq plot
qqnorm(players.data.d$PTS, pch = 1, frame = FALSE)
qqline(players.data.d$PTS, col = "steelblue", lwd = 2)
```

Normal Q-Q Plot



#histogram
hist(players.data.d\$PTS)

Histogram of players.data.d\$PTS




histograma zaključujemo da zavisna varijabla
(PTS) nije normalno distribuirana. Zato koristimo Wilcoxon-Mann-Whitney test

Iz

```
library(dplyr)
group_by(players.data.d, Position) %>%
  summarise(
    count = n(),
    median = median(PTS, na.rm = TRUE),
    IQR = IQR(PTS, na.rm = TRUE)
  )
## `summarise()` ungrouping output (override with `.groups` argument)
## # A tibble: 4 x 4
     Position count median
                             IQR
##
     <chr>
             <int> <dbl> <dbl>
## 1 C
                        16 36
                201
                        11 19
## 2 D
                300
## 3 L
                175
                        15 32.5
## 4 R
                212
                        17 34.5
library("ggpubr")
View(players.data.d)
ggboxplot(players.data.d, x = "Position", y = "PTS",
          color = "Position",
          ylab = "PTS", xlab = "Position")
```

Position \rightleftharpoons L \rightleftharpoons C \rightleftharpoons R \rightleftharpoons D



res2 <-cor.test(players.data.d\$Position_C, players.data.d\$Position_R, method = "spearman")

Warning in cor.test.default(players.data.d\$Position_C,

players.data.d\$Position_R, : Cannot compute exact p-value with ties

```
res2
##
##
    Spearman's rank correlation rho
## data: players.data.d$Position_C and players.data.d$Position_R
## S = 152055334, p-value < 2.2e-16
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##
          rho
## -0.3029104
res1 <-cor.test(players.data.d$Position_L, players.data.d$Position_R, method = "spearman")
## Warning in cor.test.default(players.data.d$Position_L,
## players.data.d$Position_R, : Cannot compute exact p-value with ties
res1
##
##
    Spearman's rank correlation rho
## data: players.data.d$Position_L and players.data.d$Position_R
## S = 149082805, p-value < 2.2e-16
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##
          rho
## -0.2774399
Prema tablici možemo zaključiti da najveći broj bodova postižu igrači na lijevom i desnom krilu, s medijanom
17.0, odnosno 15.5, što nam i potvrđuje boxplot.
kruskal.test(players.data.d$Position, players.data.d$PTS)
##
   Kruskal-Wallis rank sum test
## data: players.data.d$Position and players.data.d$PTS
## Kruskal-Wallis chi-squared = 111.56, df = 81, p-value = 0.01379
#f test
var.test(players.data.d$Position_L, players.data.d$Position_R, conf.level = 0.95, paired = T)
##
##
   F test to compare two variances
##
## data: players.data.d$Position_L and players.data.d$Position_R
## F = 0.87065, num df = 887, denom df = 887, p-value = 0.03928
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.7632155 0.9932141
## sample estimates:
## ratio of variances
            0.8706528
```

Iz provedenog F testa vidimo da se hipoteza o jednakosti varijanci ne može odbaciti na razini znacajnosti od 5%, stoga cemo u t-testu postaviti parametar var.equal na True.

```
#t test
t.test(players.data.d$Position_L, players.data.d$Position_R, conf.level = 0.95, paired = T)
##
##
   Paired t-test
##
## data: players.data.d$Position_L and players.data.d$Position_R
## t = -1.8835, df = 887, p-value = 0.05996
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -0.085083838 0.001750505
## sample estimates:
## mean of the differences
               -0.04166667
##
Iz provedenog t-testa uocavamo da je p vrijedost izuzetno malena, stoga hipotezu da su aritmeticke sredine
kategorija position L i position R jednake odbacujemo na razini znacajnosti od 5%. U nastavku cemo
provjeriti imaju li te dvije kategorije jednaku razdiobu.
wilcox.test(players.data.d$Position_L, players.data.d$Position_R, conf.level = 0.95, paired = T)
##
##
   Wilcoxon signed rank test with continuity correction
##
## data: players.data.d$Position L and players.data.d$Position R
## V = 33950, p-value = 0.06003
## alternative hypothesis: true location shift is not equal to 0
Nakon provođenja Wilcoxonova testa dobivamo jednake rezultate kao i u t-testu, dakle odbacujemo nultu
hipotezu.
ks.test(players.data.d$Position_L, players.data.d$Position_R, conf.level = 0.95, var.equal = T, paired
## Warning in ks.test(players.data.d$Position_L, players.data.d$Position_R, : p-
## value will be approximate in the presence of ties
##
##
   Two-sample Kolmogorov-Smirnov test
##
## data: players.data.d$Position_L and players.data.d$Position_R
## D = 0.041667, p-value = 0.4239
## alternative hypothesis: two-sided
Rezultati provedenog Kolmogorov-Smirnovljeva idu u prilog odbacivanju hipoteze da kategorije lijevog i
desnog krila imaju jednaku razdiobu.
#Linearna regresija
##Ovisnost pozicije o preferiranoj ruci udarca
tbl = table(players copy$Position,
            players_copy$Hand)
added_margins_tbl = addmargins(tbl)
print(added_margins_tbl)
##
##
           L R Sum
    С
         148 53 201
##
```


```
##
     D
         175 125 300
##
         150 25 175
    L
##
          64 148 212
##
    Sum 537 351 888
for (col_names in colnames(added_margins_tbl)){
  for (row_names in rownames(added_margins_tbl)){
    if (!(row_names == 'Sum' | col_names == 'Sum') ){
      cat('Očekivane frekvencije za razred ',col_names,'-',row_names,': ',(added_margins_tbl[row_names,
   }
  }
}
## Očekivane frekvencije za razred L - C:
## Očekivane frekvencije za razred L - D :
                                             181.4189
## Očekivane frekvencije za razred L - L :
                                             105.8277
## Očekivane frekvencije za razred L - R :
                                             128.2027
## Očekivane frekvencije za razred R - C :
## Očekivane frekvencije za razred R - D :
                                             118.5811
## Očekivane frekvencije za razred R - L :
                                             69.1723
## Očekivane frekvencije za razred R - R :
                                             83.7973
#chi^2 test nezavisnosti
test <- chisq.test(tbl,correct=F)</pre>
test
##
##
   Pearson's Chi-squared test
##
## data: tbl
## X-squared = 143.12, df = 3, p-value < 2.2e-16
print("p-vrijednost chi^2 testa:")
## [1] "p-vrijednost chi^2 testa:"
test$p.value
```

[1] 8.019989e-31


Dobivena p-vrijednost je jako mala, što ide u prilog odbacivanju H0 hipoteze koja pretpostavlja nezavisnost varijabli pozicija i preferirane ruke.

##Ovisnost plaće igrača o više varijabli Postoji li veza između danih varijabli i pla´ce igrača? Isprobajte nekoliko, po vama smislenih kombinacija varijabli i odredite koja od njih najbolje predvida pla´cu igrača.


```
plot(players.data$Salary, players.data$TOI) #salary vs time on ice
```




plot(players.data\$Salary, players.data\$G) #salary vs goals




plot(players.data\$Salary, players.data\$DftYr)#salary vs year drafted



plot(players.data\$Salary, players.data\$FO%) #salary vs faceoff wins




plot(players.data\$Salary, players.data\$`A1`) #salary vs first assist




```
linReg = lm(Salary ~ G , players.data)
#summary(linReg)
#plot(linReg$residuals)
#hist(linReg$residuals)
hist(rstandard(linReg))
```

Histogram of rstandard(linReg)




qqnorm(rstandard(linReg))
qqline(rstandard(linReg))

Normal Q-Q Plot



plot(linReg\$fitted.values,linReg\$residuals) #reziduale je dobro prikazati u ovisnosti o procjenama mode



year <- format(as.Date(players.data\$Born, format="%Y-%m-%d"), "%Y")
#year
#plot(as.numeric(year),linReg\$residuals)
lg = lm(players.data\$Salary ~ year + players.data\$G)
lg\$terms</pre>

linReg\$fitted.values

```
## players.data$Salary ~ year + players.data$G
## attr(,"variables")
## list(players.data$Salary, year, players.data$G)
## attr(,"factors")
                       year players.data$G
## players.data$Salary
## year
                                          0
## players.data$G
                          0
                                          1
## attr(,"term.labels")
                         "players.data$G"
## [1] "year"
## attr(,"order")
## [1] 1 1
## attr(,"intercept")
## [1] 1
## attr(,"response")
## [1] 1
## attr(,".Environment")
## <environment: R_GlobalEnv>
## attr(,"predvars")
## list(players.data$Salary, year, players.data$G)
## attr(,"dataClasses")
## players.data$Salary
                                       year
                                                 players.data$G
           "character"
##
                                "character"
                                                    "character"
qqnorm(rstandard(lg))
qqline(rstandard(lg))
```

Normal Q-Q Plot

